

POLITECHNIKA WROCŁAWSKA

WYDZIAŁ ELEKTRONIKI

KIERUNEK: INFORMATYKA

SPECJALNOŚĆ: SYSTEMY INFORMATYKI W MEDYCYNIE

PROJEKT INŻYNIERSKI

Zastosowanie klasyfikatorów do sterowania
bioprotezą dłoni – algorytmy i badania
eksperymentalne.

Classifiers applied to the control of bioprosthetic hand
- algorithms and experimental investigations.

AUTOR

Krystian Suliński

PROWADZĄCY PRACĘ

prof. dr hab. inż. Marek Kurzyński,
Katedra Systemów i Sieci Komputerowych

OCENA PRACY

*Serdecznie dziękuję swojemu promotorowi,
Panu Profesorowi Markowi Kurzyńskiemu,
za życzliwość, wyrozumiałość i cierpliwość
w trakcie przygotowywania niniejszej pracy.*

*Pragnę wyrazić swoją wdzięczność również
Michałowi Lankofowi i Oldze Kasper
za okazane mi wsparcie i dobre słowo.*

Spis treści

Rozdział 1. Wprowadzenie	5
Rozdział 2. Cel i zakres projektu	6
Rozdział 3. Podstawy teoretyczne	7
3.1 EMG	7
3.2 Anatomia przedramienia	9
Rozdział 4. Przegląd i analiza istniejących rozwiązań	10
5. Plan eksperymentu	12
5.1 Akwizycja danych	12
5.2 Wybrane ruchy	12
5.3 Umieszczenie elektrod i rejestracja sygnału	14
5.4 Wybór metod ekstrakcji cech	17
5.5 Selekcja kanałów	19
5.6 Wybór metod klasyfikacji	19
6. Dokumentacja zrealizowanego programu	21
6.1 Struktura katalogów	22
6.2 Moduł akwizycji	23
6.3 Baza ruchów	23
6.3 Baza cech	24
6.4 Moduł przeglądu zupełnego	24

6.5 Moduł analizy wyników	25
6.6 GUI.....	25
7. Analiza wyników	27
8. Wnioski końcowe	29
Literatura.....	30
Źródła internetowe	30
Spis rysunków.....	31

Rozdział 1. Wprowadzenie

Nieodłącznym elementem życia człowieka jest podejmowanie decyzji na podstawie pewnych faktów czy domysłów. Jeśliby rozpisać na czynniki pierwsze każdą życiową decyzję, to w konsekwencji wybór zawęży się do dwóch możliwości – albo możemy coś wybrać, albo nie. Przykładowo wybierając jedno z trzydziestu dań w restauracji, dwudziestudziewięciu z nich przypisujemy wartość zero, a naszemu wybranemu danu wartość jeden. Podjęliśmy zatem trzydzieści decyzji - a nie, jak mogłoby się z pozoru zdawać, tylko jedną. Fakt, że robimy to w pewien sposób automatycznie, świadczy o naszej wyszkolonej, wyewoluowanej ku temu inteligencji. Inteligencji, stworzonej do klasyfikacji w różnych okolicznościach obserwowanych zjawisk, sytuacji czy w końcu obiektów [6].

Zgola inaczej sprawy się mają jeśli musimy je przetłumaczyć na język maszynowy. Podczas pisania programów komputerowych jesteśmy zmuszeni zastanowić się jak działa nasz umysł i przekształcić tę wiedzę w ciąg zer i jedynek, który ma za zadanie odzwierciedlać pewien wycinek rzeczywistości.

Niniejsza praca traktuje o automatycznej klasyfikacji obiektów, która to dziedzina jest fundamentalnym i najbardziej rozbudowanym działem nauki nazywanej rozpoznawaniem obiektów (*ang. pattern recognition*) [5]. Wspomnianymi obiektami będą przechwycone sygnały elektromiograficzne (upraszczając - ciągi bitów), na podstawie których będę próbował dokonać klasyfikacji ruchów.

Klasyfikacja ma posłużyć za rozróżnienie gestów dłoni, a zatem klasami będą tu ruchy chwytne ręki. Dłoń sama w sobie jest skomplikowanym organem, wielce pomocnym w codziennym życiu, wręcz nieodzownym do prawidłowego funkcjonowania. Wynika stąd potrzeba tworzenia bioprotez mających zastąpić brakującą kończynę. O ile stworzenie antropomorficznej konstrukcji mechanicznej ręki jest obecnie osiągalne i realizowane z zadowalającym efektem, o tyle najtrudniejszym elementem jest proces swobodnego nią sterowania.

Rozdział 2. Cel i zakres projektu

Celem projektu jest przeprowadzenie badań akwizycji sygnałów EMG z przedramienia człowieka i na ich podstawie wykonanie badań eksperymentalnych ujawniających możliwość rozpoznawania ruchów chwytnych dłoni. Poprzez ujawniające się możliwości mam na myśli dobór odpowiednich algorytmów dotyczących akwizycji danych, ich ekstrakcję oraz klasyfikację [Rysunek 1].



Rysunek 1: Proces rozpoznawania ruchów chwytnych dłoni.

Akwizycja służy za pozyskanie sygnału z przedramienia za pomocą systemu elektrod do przetwornika analogowo-cyfrowego znajdującego się w komputerze i ich zapis w celu późniejszego przetwarzania. Ekstrakcja odpowiada za filtrację – rejestrowane sygnały charakteryzują się redundancją informacji oraz nieprzydatnymi danymi, które z punktu widzenia klasyfikacji jedynie ją zakłócają. Dobór odpowiednich metod pozwala wyekstrahować najistotniejszej najbardziej nośne informacje, które poprawią jakość i skuteczność klasyfikacji. (Wykonano m. in. wygładzenie sygnału, selekcję kanałów czy wykrycie ruchu). Klasyfikacja zaś polega na znajdowaniu odwzorowania danych w zbiór predefiniowanych klas. Głównym jej celem jest zbudowanie formalnego modelu danych, tzw. klasyfikatora, po czym przechodzi się do fazy testowania oraz predykcji nieznanych wartości.

Rozdział 3. Podstawy teoretyczne

3.1 EMG

Elektromiografia (EMG) służy do rejestracji prądów czynnościowych mięśnia. Dzięki niej możemy wyciągać wnioski dotyczące koordynacji nerwowo-mięśniowej jako współdziałania mięśni (antagonistycznych bądź synergistycznych). Badanie EMG służy do zapisu reakcji bioelektrycznych mięśnia (polaryzacji depolaryzacji) w stanie skurczu i rozkurczu czy też oceny stopnia zaangażowania mięśnia w dany ruch. Badanie to nie służy do pomiaru siły skurczu, lecz przepływającego podczas niego prądu. Jego wynikiem jest złożony układ krzywych (wykresów), które są sumą poszczególnych odprowadzeń.


Jedną z cech, którą można wyczytać z takich wykresów jest amplituda. Świadczy ona o ilości pobudzonych jednostek motorycznych (włókien mięśniowych), angażujących się w pracę mięśnia. Im jest większa, tym więcej włókien mięśniowych jest wykorzystywanych do pracy.

Kolejną cechą jest częstotliwość, która obrazuje synchronizację pobudzenia włókien mięśniowych – im jest lepsza, tym częstotliwość jest mniejsza.

Do pomiarów EMG wykorzystuje się elektrody różnego typu: powierzchniowe, wkłuwane, koncentryczne, jedno i dwubiegunowe czy też multielektrody. W moim badaniu wykorzystałem te pierwsze – umieszczane bezpośrednio na skórze – dają one zapis asynchroniczny, rejestrując interferencyjny potencjał czynnościowy z kilku jednostek neuromotorycznych. Elektrody powierzchniowe umieszcza się w strefie innerwacji bioelektrycznej – czyli w tym miejscu, gdzie znajduje się największa ilość zakończeń

nerwowych mięśnia. Niestety elektrody te są mocno podatne na wszelkiego rodzaju zakłócenia płynące z zewnątrz, takie jak zewnętrzne pole elektromagnetyczne (okolice 50 Hz), wysoka impedancja pomiędzy elektrodą a skórą oraz zachodzące tam reakcje chemiczne. Trudnymi do wyeliminowania zakłóceniami są też delikatne wędrówki elektrod jak i kabla, za pomocą którego zostały podłączone. Niedopuszczalne jest używanie podczas badania telefonów komórkowych czy też jakiegokolwiek innej zbędnej aparatury elektronicznej.

W celu zmniejszenia wpływu zakłóceń (szumów) przywykło stosować się elektrodę referencyjną, która tworzy tzw. różnicowy układ pomiarowy. Umieszcza się ją zazwyczaj na miejscu obojętnym, niewpływającym na wynik badania – w przypadku pomiarów mięśni przedramienia wygodnie jest ją umocować na stawie łokciowym bądź w okolicach nadgarstka [Rysunek 2].




Rysunek 2: Różnicowy układ pomiarowy

Ze względu na wykorzystane rodzaje elektrod rozróżniamy dwa typy wykonania badania – elektromiografię powierzchniową oraz igłową. Ta druga jest dużo mniej przyjemna dla pacjenta, ponieważ igły są wbijane pod kątem prostym we włókno mięśniowe, a głębokość ukladania jest ściśle uzależniona od wielkości i kształtu mięśnia. Dlatego ze względu na swoją inwazyjność to badanie cechuje się odczuwaniem nieprzyjemnego bólu.

3.2 Anatomia przedramienia

Przedramię to część kończyny górnej człowieka znajdujące się dokładnie pomiędzy nadgarstkiem a stawem łokciowym. Mięśnie przedramienia są poprzecznie prążkowane. Rozróżnia się kilkanaście mięśni podzielonych na trzy grupy – przednią, tylną i boczną [www.2].

Pierwsza z nich jest najsilniejszą grupą mięśniową występującą w przedramieniu – w jej skład wchodzi głównie zginacze – mięsień nawrotny obły, zginacz promieniowy nadgarstka, dłoniowy długi, zginacz łokciowy nadgarstka, zginacz powierzchniowy palców, zginacz głęboki palców, zginacz długi kciuka i nawrotny czworogłowy. Druga z nich zawiera cztery mięśnie, które swój początek biorą w nadkłykciu bocznym kości ramiennej. Do jej podstawowej funkcji zalicza się manipulowanie nadgarstkiem. W jej skład wchodzi mięsień ramiennie-promieniowy, prostownik promieniowy krótki nadgarstka oraz odwracacz. Trzecią z nich dzielimy dodatkowo na warstwę powierzchniową oraz głęboką. Warstwę powierzchniową tworzy mięsień prostownik palców, prostownik palca małego, prostownik łokciowy nadgarstka. Natomiast warstwę głęboką tworzy mięsień odwodziciel długi kciuka, prostownik długi i krótki kciuka [Rysunek 3].



Rysunek 3: Anatomia mięśni przedramienia4

Rozdział 4. Przegląd i analiza istniejących rozwiązań

Istnieje wiele prac dotyczących rozpoznawania ruchów ręki na podstawie sygnałów EMG, często we współtowarzystwie sygnałów MMG i EEG. Najlepsze efekty uzyskuje się, kiedy do ekstrakcji wykorzystuje się modele autoregresyjne [3] oraz modele klasyfikacji oparte na sztucznych sieciach neuronowych czy naiwnej klasyfikacji Bayes'a. Prace te zazwyczaj dotyczą niewielkiej ilości rozpoznawanych ruchów (zazwyczaj 5-8 klas), rzadko przekraczając 10 gestów.

Jedna z najnowocześniejszych obecnie protez *bebionic3* firmy *RSL Steeper* [www.1] oferuje 14 ruchów, jednakże co ciekawe jej konstruktorzy zdecydowali się na ręczne przestawienie kciuka – być może właśnie ze względu na małą niezawodność. Protezy zazwyczaj oferują do 8 ruchów, co jednakże w zupełności wystarcza do wykonywania podstawowych codziennych czynności.

M. Kurzyński wraz z A. Wołczowskim w swojej pracy [3] stworzyli porównanie dwóch metod klasyfikacji – algorytmu Adaline oraz wielowarstwowego modelu perceptronu odnoszących się do kilku powszechnie znanych metod: algorytmu pięciu najbliższych sąsiadów, klasyfikatora opartego o logikę rozmytą, klasyfikatora Parzena z jądrem Gaussa oraz naiwnej klasyfikacji Bayes'a. Klasyfikator wielowarstwowego modelu perceptronu osiągnął skuteczność wynoszącą 95%, zaś Adaline 93%. W eksperymencie tym można zauważyć, że wraz ze wzrostem rzędu modelu autoregresyjnego do wartości 10 poprawiała się skuteczność klasyfikacji dla obu algorytmów.

Skuteczność bliską 90% osiągnął A. Gmerek [1]. Podczas ekstrakcji danych posiłkował się on transformatą Fouriera, natomiast do klasyfikacji użył zespołu klasyfikatorów. Zespół ten składał się on z dwóch sieci neuronowych oraz klasyfikatorów opartych o metody rozmyte.

A. Wołczowski oraz T. Suchodolski w swojej wspólnej pracy [8] także zastosowali transformatę Fouriera do ekstrakcji cech, zaś do klasyfikacji posłużyła im kombinacja drzew decyzyjnych ze sztucznymi sieciami neuronowymi. Uzyskali oni skuteczność wynoszącą 82% dla arsenału jedenastu ruchów.

Rozdział 5. Plan eksperymentu

Znalezienie najlepszego algorytmu do rozpoznawania gestów dłoni to proces składający się z wielu etapów. Najpierw dane trzeba pozyskać, następnie dokonać ekstrakcji cech sygnału, a na podstawie wygenerowanego zestawu cech dokonać jego klasyfikacji.

Zaplanowano pozyskanie sygnałów w laboratorium Wydziału Elektroniki Politechniki Wrocławskiej za pomocą dostępnych tam narzędzi. Następnie w planie było wstępne przefiltrowanie uzyskanych sygnałów i dokonanie klasyfikacji na podstawie uzyskanych danych, wykorzystując do tego środowisko Matlab i dostępne do niego biblioteki i rozszerzenia. Dodatkowym założeniem było takie dobranie metod ekstrakcji aby skuteczność klasyfikacji była jak najwyższa

5.1 Akwizycja danych

Zadaniem akwizycji danych jest zapis sygnału EMG w trakcie wielokrotnego wykonywania ściśle określonych wcześniej ruchów. Dane pobierałem z siebie samego przy pomocy osoby w laboratorium, która pomagała mi sterować programem komputerowym, abym mógł skupić się jedynie na wykonywanych ruchach, ich precyzji oraz powtarzalności.

5.2 Wybrane ruchy

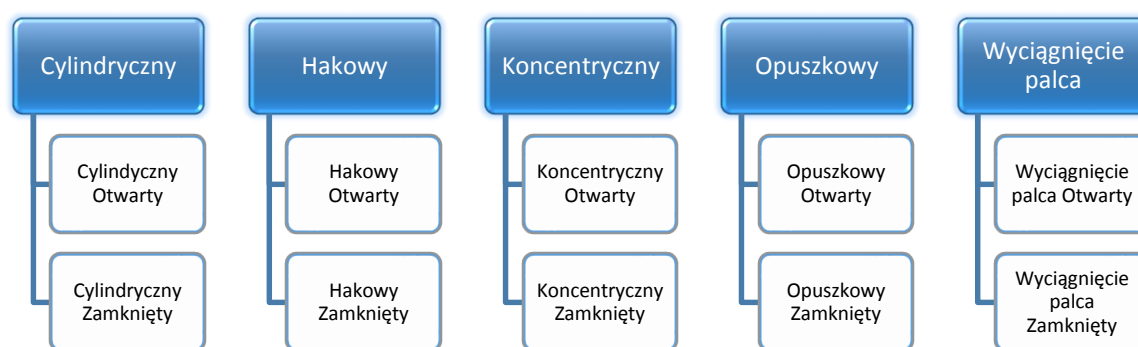
Zdrowa ludzka ręka posiada w swoim wachlarzu ruchów niekończące się kombinacje gestów, sekwencje zginania palców, ruchy chwytne czy manipulacyjne oraz zdolności

do uczenia się i zwiększania precyzji. Dowód tej tezy jak i całe jej piękno można obserwować spoglądając na muzyków grających na instrumentach klawiszowych – pianistów, czy strunowych – np. gitarzystów, jak i wszelkiej maści sportowców – wspinaczy skałkowych czy koszykarzy. Wprawa jaką posługują się oni swoimi rękami jest wprost zdumiewająca. Być może nigdy nie zostanie ona osiągnięta za pomocą protez mechanicznych. Jednakże w codziennym życiu zakres niezbędnych ruchów jest znacznie uboższy – już zgoła 6 gestów wystarczy, aby poradzić sobie w rutynowych sytuacjach. Przykładowo popularne rozróżnienie Schlesiengera wyróżnia 6 podstawowych chwytów: cylindryczny, szczypcowy, hakowy, dłoniowy, sferyczny oraz lateralny [Rysunek 4].



Rysunek 4: Ruchy chwytne wg Schlesiengera.

Biorąc pod uwagę istniejące rozwiązania oraz powyższe rozróżnienie dokonałem wyboru 10 ruchów dłoni z czego każdy gest składał się z dwóch ruchów – otwarcia i zamknięcia [Rysunek 5]. Przykładowo dla ruchu cylindrycznego, ruch zamknięty to przejście ze spoczynku do chwycenia butelki i jej trzymanie, a ruch otwarty to przejście z trzymanie butelki, poprzez poluzowanie uchwytu do stanu spoczynku. Za ruch koncentryczny rozumiem ruch podniesienia wszystkimi palcami naraz telefonu komórkowego ze stołu.



Rysunek 5: Spis wykonanych ruchów.

5.3 Umieszczenie elektrod i rejestracja sygnału


Wybór miejsca na przedramieniu do zamocowania elektrod powierzchniowych wybrano na podstawie zaangażowania mięśni w ruchy chwytne [Tabela 1]. Był wykorzystywany jeden i ten sam sposób umieszczenia elektrod przy rejestracji wszystkich powyższych gestów, tak aby zachować jednolitość i powtarzalność badania.

Tabela 1: Zestawienie mięśni odpowiedzialnych za aktywność konkretnych części dłoni.

Mięsień	kciuk	wskazujący	środkowy	serdeczny	mały	nadgarstek
Pronator teres						+
Flexor carpi radialis						+
Palmaris longus						+
Flexor carpi ulnaris						+
Flexor digitorum superficialis	+	+		+	+	+
Flexor digitorum profundus		+	+	+	+	+
Flexor pollicis longus	+					+
Pronator quadratus						

Brachioradialis						
Extensor carpi radialis longus						+
Extensor carpi radialis brevis						
Supinator						
Extensor digitorum		+	+	+	+	
Extensor digitiminimi					+	
Extensor carpi ulnaris						
Abductor pollicis longus						
Extensor pollicis brevic	+					
Extensor pollicis longus	+					+
Extensor indicis		+				

Na podstawie powyższej tabeli wybrano 5 najbardziej reprezentatywnych mięśni (zielony kolor wierszy) oraz dobrano 3 wedle własnego uznania. I tak elektroda nr 6 odpowiada za wychwytywanie ruchów palca serdecznego od wewnętrznej strony przedramienia, elektroda nr 7 za wychwycenie mięśnia extensor digitorum [Rysunek 6], a elektroda nr 8 za wychwycenie tego samego mięśnia co elektroda nr 3 lecz w innym miejscu, wg mnie bardziej reprezentatywnym.



Rysunek 6: Strzałka pokazuje umiejscowienie mięśnia extensor digitorum.

W konsekwencji 8 elektrodom przypisano 8 mięśni [Tabela 2].

Tabela 2: Zależność elektrody - mięśnie.

Elektrody	Przypisane im mięśnie
1	Flexor digitorum superficialis
2	Flexor digitorum profundus
3	Flexor digitorum
4	Flexor pollicis longus
5	Extensor pollicis longus
6	Serdeczny (brak zdefiniowanego mięśnia)
7	Extensor digitorum
8	Flexor digitorum (inne położenie niż 3)



Rysunek 7: Umieszczenie elektrod na wewnętrznej części mojego przedramienia.



Rysunek 8: Umieszczenie elektrod na zewnętrznej części mojego przedramienia.

Jak widać na powyższych fotografiach [Rysunek 7 i 8], umiejscowienie elektrod na moim przedramieniu wypełnia mniej więcej cały odcinek pomiędzy stawem łokciowym a nadgarstkiem. Jednak przy wyborze ruchów nie można się tym kierować, bowiem w przedramieniu znajduje się wiele mięśni odpowiadających za „przyczepienie” jego do stawu łokciowego i bicepsa.

5.4 Wybór metod ekstrakcji cech

Metody do ekstrakcji cech wybrałem na podstawie analizy istniejących już rozwiązań oraz własnych spostrzeżeń. Nie jest to proste zadanie, bowiem popełnienie „błędu” w tym miejscu będzie skutkować nawarstwianiem się jego skutków w dalszym procesie klasyfikacji. Zastosowanie nieodpowiedniej metody ekstrakcji może skutkować tym, że obiekty będą nierozróżnialne i nie będzie możliwa ich późniejsza poprawna klasyfikacja.

Nie istnieje optymalne kryterium oceny jakości ekstrakcji cech, które można by zastosować w wybranym celu. W związku z tym, za ocenę jakości ekstrakcji przyjąłem

kończącą jakość klasyfikacji. W niniejszej pracy przetestowałem takie metody ekstrakcji jak modele autoregresyjne, transformatę Fouriera, całkowitą energię sygnału czy metody amplitudowo-częstotliwościowe. Kończącym wynikiem wyznaczyłem ocenę jakości klasyfikacji dla kombinacji trzech z powyższych metod. Poniżej przedstawiam kompletny spis metod ekstrakcji wykorzystanych podczas realizacji projektu [Tabela 3].

Tabela 3: Metody ekstrakcji.

Nazwa algorytmu oraz opis parametrów	
Całkowita energia sygnału	Współczynniki autoregresji Burga
<i>Bezparametryczna</i>	<i>1</i> - stopień autoregresji obwiedni
Suma wartości bezwzględnych	Aproksymowana obwiednia FFT
<i>Bezparametryczna</i>	<i>1</i> - stopień aproksymacji
	<i>2</i> - wygładzanie obwiedni
Wartość skuteczna sygnału	Współczynniki autoreg. obwiedni FFT
<i>Bezparametryczna</i>	<i>1</i> - stopień autoregresji obwiedni
	<i>2</i> - wygładzanie obwiedni
Ilość przejść przez zero	Krótko czasowa transformata Furiera
<i>Bezparametryczna</i>	<i>Bezparametryczna</i>
Ilość przejść przez zero z progiem	Cechy MFCC
<i>1</i> – próg	<i>Bezparametryczna</i>
Aproksymowana obwiednia sygnału	Indeksy najaktywn. przedziałów FFT
<i>1</i> - stopień aproksymacji	<i>1</i> - ilość przedziałów podziału
<i>2</i> - wygładzanie obwiedni	<i>2</i> - ilość najaktywniejszych przedziałów
Indeksy najaktywniejszych przedziałów	Aproksymowana obwiednia falki
<i>1</i> - ilość przedziałów podziału	<i>1</i> - numer iteracji falki
<i>2</i> - ilość najaktywniejszych przedziałów	<i>2</i> - nazwa falki
	<i>3</i> - stopień aproksymacji

5.5 Selekcja kanałów

Podczas procesu akwizycji sygnału zostało użyte 8 elektrod, która to ilość może, lecz nie musi być nadmiarowa. W celu sprawdzenia przydatności do klasyfikacji wszystkich kanałów trzeba zbadać ich niezależność. Każdy poszczególny sygnał może być potraktowany jako realizacja jakiejś zmiennej losowej, zatem sygnały (kanały) powinny być od siebie niezależne. Niezawsze się jednak tak dzieje, ponieważ w przypadku używania elektrod powierzchniowych występuje zjawisko przesłuchu, a zatem nakładania się tych samych sygnałów na różne kanały.

W związku z tym trzeba użyć matematycznych narzędzi do oszacowania liczby niezależnych zmiennych losowych, gdzie z pomocą przychodzi metoda czynników głównych (PCA). Polega ona na redukcji wymiaru danych opartych o konstrukcję nowych, liniowo niezależnych zmiennych dzięki kombinacji liniowej danych wejściowych. Nie zachodzi potrzeba dogłębnego opisu sposobu działania tej metody, gdyż jest ona powszechnie znana i dokładny jej opis jest szeroko traktowany w literaturze [4].

Po jej zastosowaniu dowiedziano się, że skuteczność rozpoznawania rosła od 1 do 7 kanału, a dla ósmego już malała. Ósmym kanałem w tym przypadku była elektroda nr 8, która, jak się okazało, nie została najszczęśliwiej umocowana, bowiem powieliła w dużym stopniu sygnał z kanału 3 (z elektrody nr 3), a zatem była od niej liniowo zależna. W konsekwencji kanał 8 został odrzucony na etapie ekstrakcji w celu podniesienia jakości klasyfikacji.

5.6 Wybór metod klasyfikacji

Wyniki działania klasyfikatorów różnią się skutecznością z wielu przyczyn, dlatego wybrałem aż kilkadziesiąt różnych algorytmów w celu znalezienia najlepszego sposobu rozpoznawania sygnałów. Analiza dyskryminacji została oparta m. in. algorytmy:

- k najbliższych sąsiadów (*k-nearest neighbour classifier (find k, build classifier)*)
- naiwnej klasyfikacji Bayes'a (*naive Bayes classifier*)
- sztucznej sieci neuronowej (*automatic neural network classifier*)
- metody najmniejszych kwadratów (*minimum least square linear classifier*)

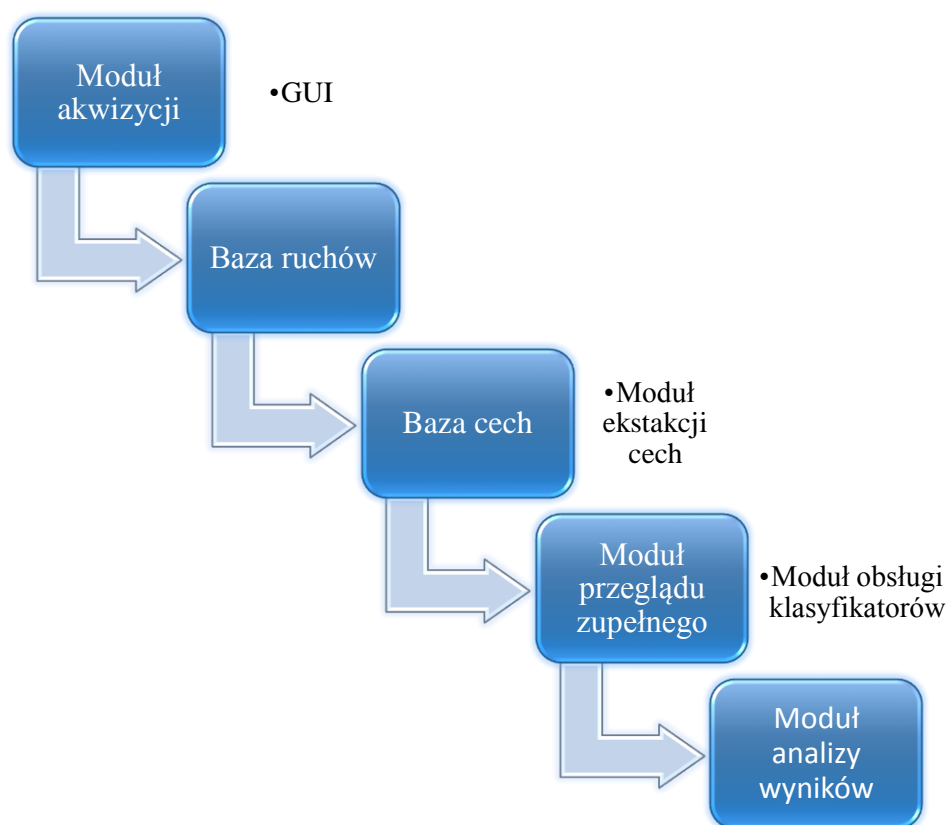
Poniżej przedstawiam kompletny spis wszystkich użytych metod klasyfikacji [Tabela 4], które będą implementowane przy pomocy biblioteki PRT oraz LIBSVM w środowisku Matlab.

Tabela 4: Metody klasyfikacji.

METODY KLASYFIKACJI	
Logistic linear classifier	Decision tree classifier from the Stats toolbox
Nearest mean linear classifier	Breiman's random forest classifier
Minimum least square linear classifier	Naive Bayes classifier
Normal densities based linear (multi-class) classifier	Naive Bayes classifier from the Stats toolbox
Scaled nearest mean linear classifier	Feed forward neural network classifier by backpropagation
Quadratic classifier	Feed forward neural network by Levenberg-Marquardt rule
Normal densities based quadratic (multi-class) classifier	Linear perceptron
Uncorrelated normal densities based quadratic classifier	Random neural network classifier
Linear classifier based on KL expansion of common cov matrix	Automatic neural network classifier
Linear classifier based on PCA expansion on the joint data	Feed-forward neural net classifier back-end routine
Add polynomial features and run arbitrary classifier	Manhattan distance feature based dissimilarity space classifier
Subspace classifier	Voted perceptron classifier
k-nearest neighbour classifier (find k, build classifier)	Feature based dissimilarity space classifier
k-nearest neighbour classifier from the Stats toolbox	Discriminative restricted Boltzmann machine classifier
Parzen classifier	Support vector classifier nr 1
Parzen density based classifier	Support vector classifier nr 2
Construct binary decision tree classifier	Support vector classifier nr 3
Decision tree classifier, rewritten, also for nominal features	Support vector classifier nr 4

Rozdział 6. Dokumentacja zrealizowanego programu

Program składa się z modułów i baz, tworząc jednolity zbiór hierarchiczny [Rysunek 9], z których każdy kolejny element przetwarza przyjęte dane z wcześniejszego. Całość została napisana w środowisku *Matlab & Simulink Student Version – Release 2013a* z wykorzystaniem bibliotek *PRT - Pattern Recognition Tools* (Toolbox for representation and generalization) oraz *LIBSVM – A Library for Support Vector Machines*.



Rysunek 9: Składowe programu.

6.1 Struktura katalogów

Program dzieli się na trzy części. W pierwszej z nich znajdują się foldery z bazą ruchów i bazą cech, wynikami przeglądu oraz załączonymi bibliotekami (wspomniane PRT i LIBSVM). W drugiej znajdują się funkcje obsługi przetwornika (funkcje akwizycji) i funkcje generacji cech, klasy ruchów oraz klasyfikatory z funkcjami uczenia oraz testowania. W trzeciej części znajdują się trzy skrypty – inicjacji GUI, obsługujący zmienne globalne oraz skrypt testowy do weryfikacji działania poprawności programu [Rysunek 10].



Rysunek 10: Struktura katalogów.

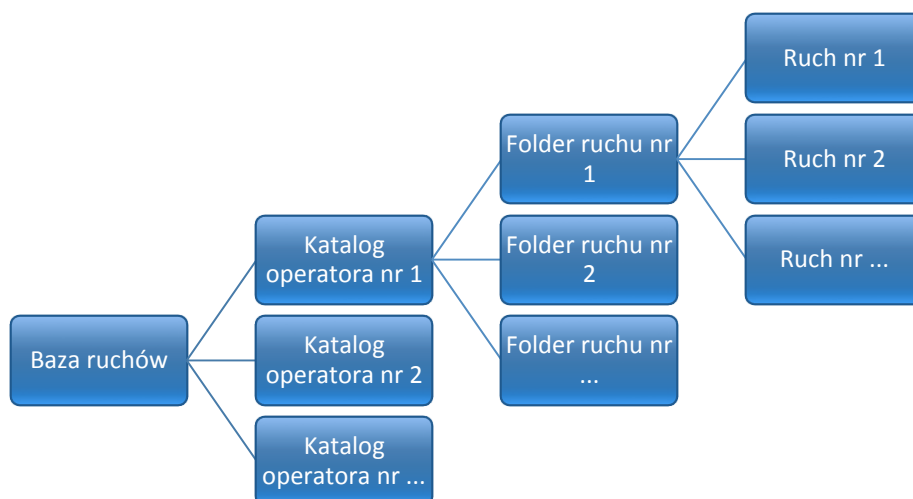
6.2 Moduł akwizycji

Moduł akwizycji odpowiada za pobieranie i rejestrowanie sygnału, który jest następnie zapisywany bezpośrednio w bazie ruchów. Oprócz samego sygnału odnotowywane są następujące informacje:

- czas trwania ruchu,
- częstotliwość próbkowania sygnału,
- ilość wykorzystywanych podczas akwizycji elektrod,
- nazwa operatora (osoby z której zostały pozyskane sygnały).

6.3 Baza ruchów

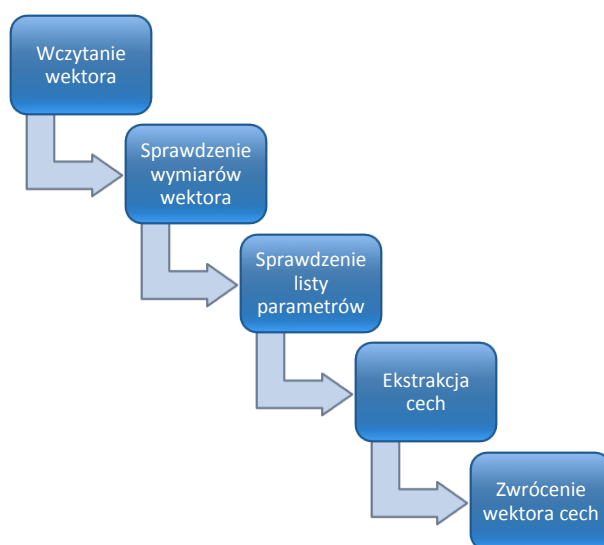
Baza ruchów przechowuje 10 gestów, z czego każdy gest został wykonany 150 razy. Klasa ta pozwala na wygodne przechowywanie instancji pomiarów, umożliwiając podstawowe operacje, takie jak zapis, zwracanie parametrów oraz formułowanie zapytań w celu wczytania ruchów. Sygnały pobierane od różnych operatorów (co jednak w przypadku tej pracy nie występuje, jednakże ta funkcjonalność może zostać wykorzystana w przyszłości) są przechowywane w odrębnych katalogach [Rysunek 10].



Rysunek 11: Struktura bazy ruchów.

6.3 Baza cech

Kolejnym etapem po rejestracji (akwizycji) sygnału jest ekstrakcja danych, której wyniki są zapisywane w Bazie cech. Klasa generatora cech zawiera w sobie metody potrzebne do wyekstrahowania cech z danego kanału akwizycji. Klasa ta na wejściu przyjmuje wektor, który jest rozumiany jako struktura danych o wymiarze [ilość kanałów] x [częstotliwość próbkowania] (sygnał trwający trzy sekundy o częstotliwości próbkowania wynoszącej 1000, pobrany za pomocą 7 elektrod ma wymiar 7x3000). Po jego wczytaniu następuje sprawdzenie zgodności oczekiwanych wymiarów oraz listy parametrów. Zgodnie z tym co pisałem we wcześniejszym podrozdziale [5.4 Wybór metod ekstrakcji cech], niektóre algorytmy ekstrakcji cech są parametryczne (np. autoregresja Burga wymaga podania stopnia autoregresji obwiedni) i w tym miejscu następuje ich sprawdzenie. Następnie sygnał może zostać poddany właściwej ekstrakcji, a potem zwrócony na wyjście w postaci wektora cech [Rysunek 12].



Rysunek 12: Schemat postępowania klasy generatora cech.

6.4 Moduł przeglądu zupełnego

Taki to wektor cech jest przygotowany do klasyfikacji. Wówczas łączy się moduł przeglądu zupełnego z obsługą klasyfikatorów. Moduł ten służy do wykonania kompleksowego testu klasyfikatorów – w chwili obecnej umożliwia on jedynie

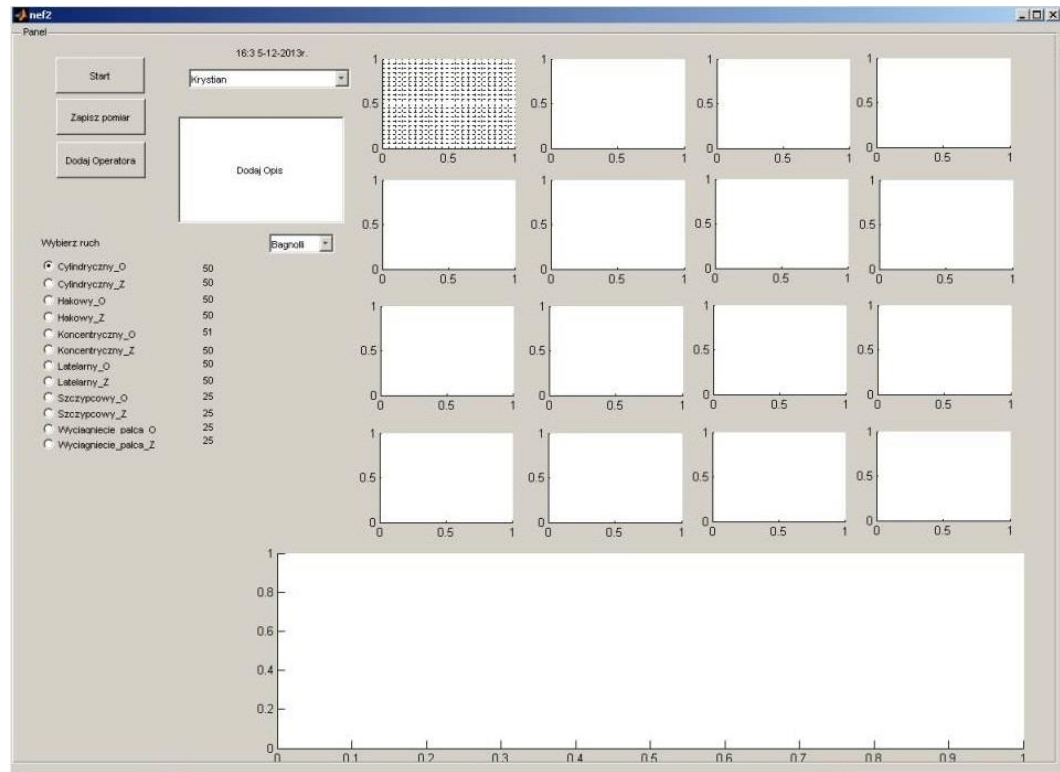
przegląd zupełny, zaś docelowo powinien posiadać algorytmy pozwalające na redukcję złożoności testu. Za przegląd zupełny rozumiem dobieranie wszystkich możliwych kombinacji metod ekstrakcji oraz przepuszczanie ich przez klasyfikatory (czego złożoność uwidacznia długi czas działania programu). W jego skład wchodzi funkcja wykonująca przegląd zupełny klasyfikatorów i zaimplementowanych metod ekstrakcji cech, funkcja przygotowująca wektory uczące oraz testujące dla klasyfikatorów wraz z funkcją przygotowującą listę algorytmów ekstrakcji cech (dokładnie tych, które zostały użyte to utworzenia bazy cech). Posiada on również funkcję przygotowującą macierz ze wszystkimi kombinacjami użycia algorytmów ekstrakcji cech. Jej parametry – min i max – mówią o tym ile algorytmów powinno się znaleźć w wynikowych kombinacjach.

6.5 Moduł analizy wyników

Moduł przeglądu zupełnego po swoim działaniu przesyła wyniki bezpośrednio do modułu analizy wyników. Moduł analizy wyników służy do archiwizacji oraz analizy wyników pozyskanych podczas przeglądu. Pozwala on na zapisanie danych dotyczących uczenia oraz testowania algorytmów klasyfikacji. Jego istotną funkcją jest scalanie (agregacja) wyników z danego folderów, bowiem efektem pracy przeglądu jest kilka plików.

6.6 GUI

Rejestrację sygnałów przeprowadza się za pomocą graficznego interfejsu użytkownika [Rysunek 14], który w wygodny sposób umożliwia ich pozyskiwanie i zapis. W celu zachowania precyzji wykonywanych ruchów poprosiłem drugą osobę o pomoc w obsłudze programu, podczas gdy ja skupiłem się na ruchach. Na początku sądziłem, że przydałaby się funkcja metronomu, abym wykonywał ruchy zawsze w tej samej sekundzie trwania ruchu, jednakże procesy ekstrakcji dowiodły, że nie jest to konieczne.



Rysunek 13: Interfejs użytkownika do akwizycji danych.

Jest w nim możliwość wyboru operatora (już istniejącego bądź stworzenia nowego). Po kliknięciu przycisku *Start* rozpoczyna się akwizycja sygnałów z elektrod (maksymalnie 16 kanałów – stąd widoczne 16 wykresów). Po przebiegu pomiaru wyświetlającego się w głównym oknie na dole, możemy zapisać pomiar do jednego z ruchów (do podfolderu *Bazy ruchów*) bądź też nie zrobić nic – wówczas po ponownym kliknięciu przycisku *Start* sygnał ulegnie bezpowrotnemu zniszczeniu. Obok nazw wykonywanych ruchów pojawia się liczba informująca o ilości zarejestrowanych już ruchów dla tej *Bazy*.

Rozdział 7. Analiza wyników

Jak już nadmieniono przegląd zupełny generuje całą masę wyników w zależności od dobranych metod ekstrakcji. Wynikiem działania programu jest plik tekstowy. Plik ten dzieli się najogólniej na dwie sekcje: w pierwszej wypisane są użyte metody ekstrakcji (oraz opcjonalnie ich parametry), a w drugiej skuteczność klasyfikacji dla poszczególnych ruchów.

Druga sekcja ze względu na swoją złożoność wymaga komentarza. Mianowicie składa się ona z 12 kolumn i ilości wierszy odpowiadającej ilości użytych klasyfikatorów. W kolumnie nr 1 zostają wypisane nazwy klasyfikatorów (skrótowo, np. *knnc* to *k-nearest neighbour classifier*). W kolumnach 2-11 wyświetlana jest skuteczność danego klasyfikatora dla ruchów od nr 1 do nr 10. Zaś w kolumnie 12 obliczana jest średnia arytmetyczna skuteczności wszystkich ruchów (z kolumn 2-11). Ta średnia odpowiada za końcową jakość klasyfikacji.

Spotykanym wynikiem jest wartość 1.0 (100%) dla jednego ruchu i 0.0 (0%) dla pozostałych, co daje skuteczność 0.1 (10%). Wartość -1.00 oznacza błąd.

Najlepsze wyniki uzyskuje się po wybraniu następującej kombinacji metod ekstrakcji:

- obwiednia szybkiej transformaty Fouriera autoregresja rzędu 10
- aproksymowana obwiednia falki rzędu 5,
- autoregresja Burga rzędu 10.

Dla tak dobranych parametrów największą skuteczność wykazał klasyfikator k-najbliższych sąsiadów (*knnc*) odnosząc wynik na poziomie 84%. Tylko o jeden punkt procentowy gorszy okazał się klasyfikator najmniejszych kwadratów (*fisher*).

```

1 # cechy_obwiednia_FFT_autoregresja_10_200
2 # cechy_obwiednia_falki_autoregresja_5_sym10_10_200
3 # cechy_autoregresja_burga_10
4
5 knnc [ 0.91 0.78 0.76 0.87 0.42 0.82 0.93 1.00 0.91 0.96 ] 0.84
6 fisherc [ 0.91 0.78 0.67 0.87 0.42 0.82 0.93 1.00 0.91 0.96 ] 0.83
7 fdsc [ 0.91 0.78 0.71 0.91 0.33 0.64 0.93 0.96 0.93 0.98 ] 0.81
8 nulibsvc [ 0.93 0.73 0.60 0.89 0.42 0.69 1.00 0.91 0.93 0.96 ] 0.81
9 libsvc [ 0.87 0.76 0.73 0.84 0.29 0.84 0.73 1.00 0.64 0.71 ] 0.74
10 klldc [ 0.98 0.71 0.60 0.93 0.38 0.56 0.78 0.91 0.64 0.60 ] 0.71
11 naivebc [ 0.69 0.73 0.38 0.82 0.31 0.22 0.84 0.80 0.84 0.09 ] 0.57
12 ldc [ 0.98 0.62 0.20 0.22 0.02 0.02 0.24 0.78 0.56 0.76 ] 0.44
13 nmc [ 1.00 0.31 0.27 0.11 0.09 0.27 0.02 0.11 0.04 0.02 ] 0.22
14 dtc [ 0.00 0.00 1.00 0.00 0.00 0.00 0.00 0.00 0.00 1.00 ] 0.20
15 nmssc [ 1.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 ] 0.10
16
17 knnc K-Nearest Neighbor Classifier
18 fisherc Fisher's Least Square Linear Classifier
19 fdsc Feature based Dissimilarity Space Classification
20 nulibsvc Support Vector Classifier by libsvm, nu version r
21 libsvc Support Vector Classifier by libsvm
22 klldc Linear classifier built on the KL expansion of the common covariance matrix
23 naivebc Naive Bayes classifier
24 ldc Linear Bayes Normal Classifier
25 nmc Nearest Mean Classifier
26 dtc Decision tree classifier
27 nmssc Nearest Mean Scaled Classifier

```

Rysunek 14: Wyniki klasyfikacji

Rozdział 8. Wnioski końcowe

Założenia projektowe zostały spełnione z zadowalającym efektem. Dodatkowym plusem jest pozostawienie pracy w formie otwartej, możliwej do swobodnej rozbudowy.

Aby zrealizować projekt trzeba było gruntownie zapoznać się z metodami ekstrakcji cech, akwizycji sygnału i metodami automatycznej klasyfikacji obiektów, jak i selekcji i redukcji informacji. Następnie trzeba było pozyskać sygnał, który to proces był żmudny, długotrwały i z powodu swej charakterystyki nietrudno było o błędy.

Z pewnością większą skuteczność klasyfikacji uzyskałoby się stosując zespoły klasyfikatorów (multiklasyfikatory) [2], czy też metody fuzji. Można by również pozyskać większą liczbę sygnałów, np. z EEG czy z MMG.

W niniejszej pracy zauważa się braki dotyczące redukcji i selekcji sygnałów, którego skutkiem jest m. in. wolny czas działania programu. Zaleca się zastosowanie metody selekcji na podstawie teorii decyzji statystycznych czy wykorzystujących teorię informacji.

Projekt można rozbudować w ten sposób, aby pobierane dane w czasie rzeczywistym natychmiast klasyfikować i rozpoznawać, tak jak ma to miejsce w działających już bioprotezach.

Literatura

1. Gmerek A., *An Adaptive Used Surface Electromyography Controlling System of the Hand Prosthesis*, Prace Naukowe Politechniki Warszawskiej - Elektronika 2010, vol. 1, str. 99-110.
2. Kuncheva L. I., *Combining Pattern Classifiers. Methods and Algorithms*, Wiley-Interscience 2004.
3. Kurzyński M., Wołczowski A., *Neural Networks with AR Model Coefficients Applied to the EMG Signal Classification*, ANNIIP (2010), str. 81-86.
4. Maaten L., *An Introduction to Dimensionality Reduction Using Matlab*, Maastricht 2007.
5. Sapor K., *Automatyczna klasyfikacja obiektów*, Akademicka Oficyna Wydawnicza EXIT, Warszawa 2005.
6. Sobczak W., Malina W., *Metody selekcji i redukcji informacji*, Wydawnictwo Naukowo-Techniczne, Warszawa 1985, str. 9-17.
7. Tax D., Duin R. P. W., Loog M., Pękalska E., *Feature-Based Dissimilarity Space Classification*, In: ICPR 2008, vol. (3).
8. Wołczowski A., Suchodolski T., *Sterowanie bioprotezą dłoni na poziomie interakcji człowiek-maszyna*, Prace Naukowe Elektronika 2008, str. 389-398.

Źródła internetowe

www1. http://bebionic.com/the_hand - strona producenta bioprotezy *bebionic*3.

www2. <http://dietyitrening.eu/najlepsze-cwiczenia-na-przedramiona/> - zdjęcia ręki.

Spis rysunków

Rysunek 1: Proces rozpoznawania ruchów chwytnych dłoni	6
Rysunek 2: Różnicowy układ pomiarowy	8
Rysunek 3: Anatomia mięśni przedramienia ⁴	9
Rysunek 4: Ruchy chwytne wg Schlesiengera.	13
Rysunek 5: Spis wykonanych ruchów.	14
Rysunek 6: Strzałka pokazuje umiejscowienie mięśnia extensor digitorum.	15
Rysunek 7: Umieszczenie elektrod na wewnętrznej części mojego przedramienia.	16
Rysunek 8: Umieszczenie elektrod na zewnętrznej części mojego przedramienia.	17
Rysunek 9: Składowe programu.	21
Rysunek 10: Struktura katalogów.	22
Rysunek 11: Struktura bazy ruchów.	23
Rysunek 12: Schemat postępowania klasy generatora cech.	24
Rysunek 13: Interfejs użytkownika do akwizycji danych.	26
Rysunek 14: Wyniki klasyfikacji.....	28